Análisis de la Relación entre Salud y Sueño

Ruiz Espinoza Victor Angel

5 de Junio, 2025

1. Resumen Ejecutivo

Este análisis presenta un estudio comprehensivo sobre la relación entre diversos factores de salud y estilo de vida con los trastornos del sueño. Se implementaron y compararon cuatro modelos de aprendizaje automático para predecir la presencia de problemas de sueño (insomnio y apnea del sueño) en una población de 374 individuos.

2. Descripción de la Base de Datos

2.1. Fuente de los Datos

Los datos utilizados en este análisis provienen del dataset ***"Health and Sleep Relation 2024"*** disponible en Kaggle: (https://www.kaggle.com/datasets/orvile/health-and-sleep-relation-2024). Este conjunto de datos fue desarrollado con financiamiento de la Universidad de Oxford (OXFDU1245) y está diseñado específicamente para explorar la relación entre patrones de sueño y salud general. El dataset incluye información detallada sobre hábitos de sueño individuales, métricas de salud y factores de estilo de vida, permitiendo analizar cómo la calidad y duración del sueño impactan el bienestar físico y mental. Su enfoque se centra en la promoción de la salud y el mantenimiento de la salud, apoyando investigaciones sobre higiene del sueño, condiciones de salud crónicas, salud mental e influencias del estilo de vida en el sueño.

2.2. Características Generales

- **Tamaño de la muestra:** 374 observaciones
- **Variables originales:** 13 características
- **Variable objetivo:** Trastornos del sueño (Insomnio, Apnea del Sueño, Ninguno)
- **Distribución de trastornos:**
  - Insomnio: 77 casos (20.6 %)
  - Apnea del Sueño: 78 casos (20.9 %)
  - Sin trastornos: 219 casos (58.6 %)

2.3. Variables Incluidas

Variable	Descripción
Edad	Edad del participante
Género	Masculino/Femenino
Ocupación	Profesión del participante
Duración del Sueño	Horas de sueño por noche
Calidad del Sueño	Puntuación de 0-10
Nivel de Actividad Física	Puntuacion de 0-10
Nivel de Estrés	Escala de estrés percibido
Categoría de IMC	Normal/Sobrepeso/Obesidad
Presión Arterial	Sistólica/Diastólica
Frecuencia Cardíaca	Latidos por minuto
Pasos Diarios	Número de pasos por día

Cuadro 1: Variables del conjunto de datos

3. Transformaciones de los Datos

3.1. Preprocesamiento Realizado

1. **Conversión de variables categóricas:** Se transformaron variables de texto a factores para su análisis estadístico.
2. **Separación de presión arterial:** La variable de presión arterial se dividió en dos componentes:
   - Presión sistólica
   - Presión diastólica
3. **Estandarización de escalas:**
   - Pasos diarios convertidos a miles de pasos
   - Nivel de estrés escalado de 0-100
4. **Variable objetivo binaria:** Se creó la variable *Problemas de Sueño* combinando insomnio y apnea del sueño vs. ningún trastorno.
5. **División de datos:** 80 % entrenamiento (300 obs.) y 20 % prueba (74 obs.).

4. Análisis Exploratorio de Datos

4.1. Distribución de Variables Numéricas

[!H]
[Insertar aquí las gráficas de distribución de variables numéricas]

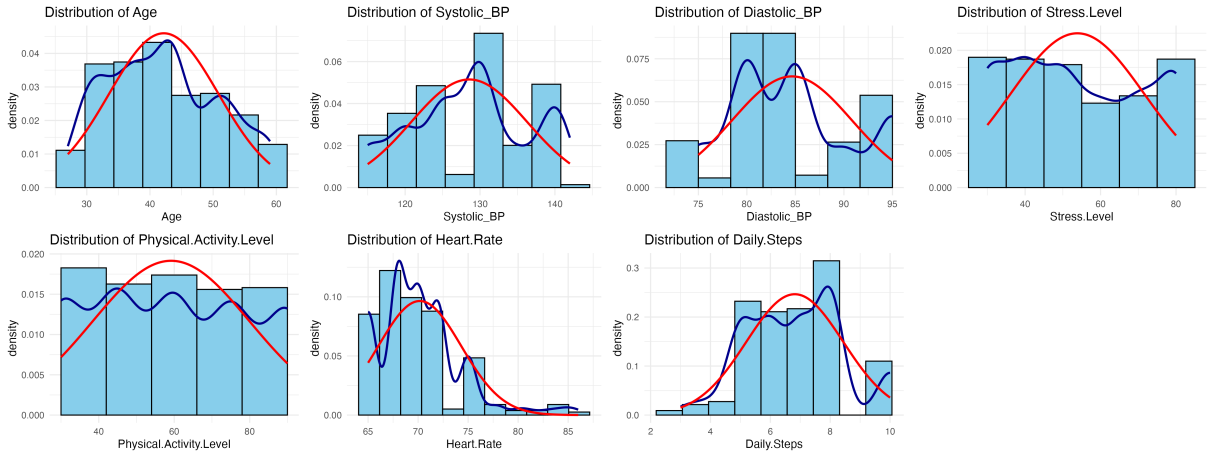


Figura 1: Histograma de las variables numéricas

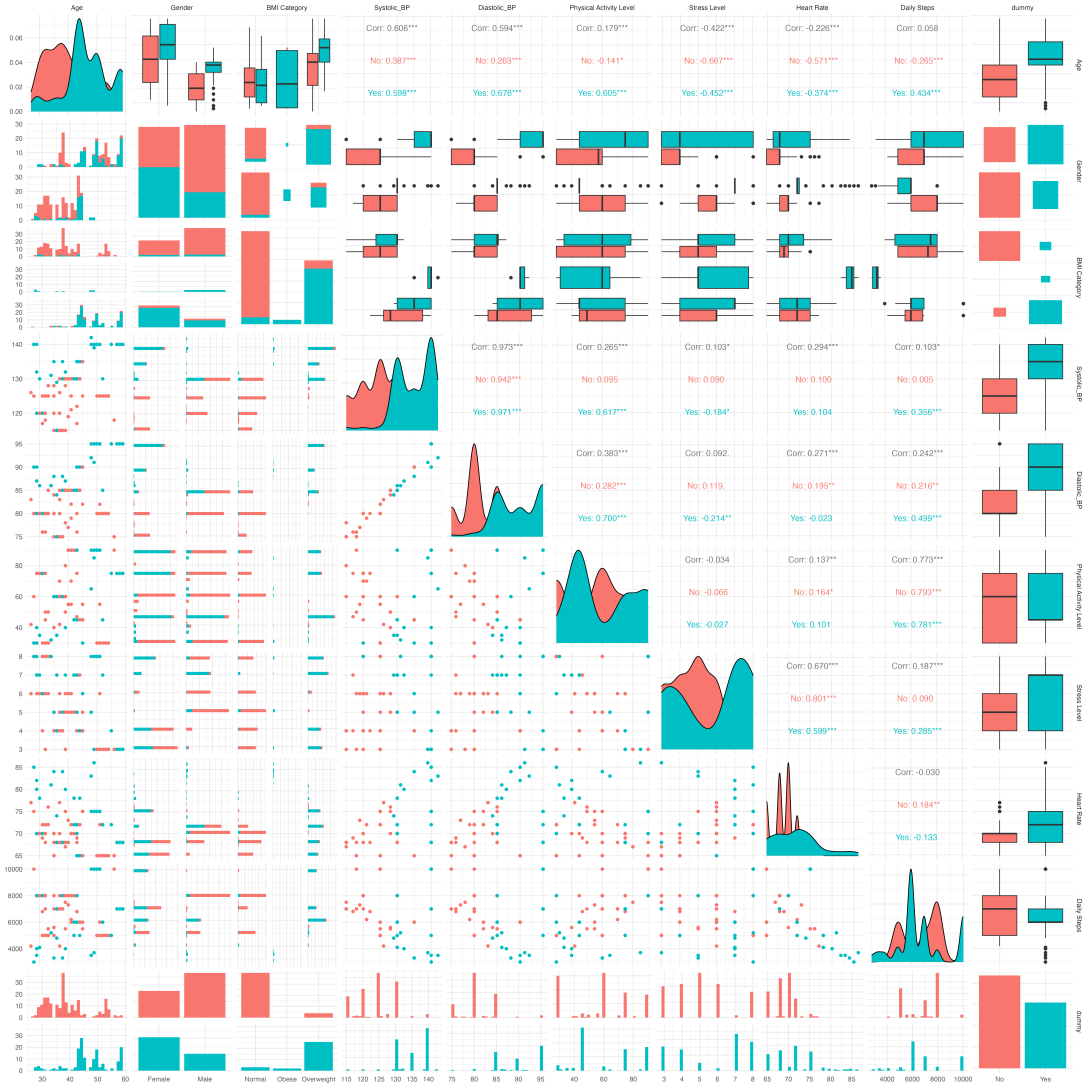


Figura 2: Grafico de pares de todas las variables, dividido por presencia de trastornos de sueño

4.2. Interpretación de las Gráficas

[Completar con la interpretación de las distribuciones observadas en las gráficas]

5. Modelos Implementados

5.1. Modelo de Regresión Logística

5.1.1. Modelo Completo

El modelo inicial incluyó todas las variables disponibles, mostrando que varias no eran estadísticamente significativas.

5.1.2. Modelo Optimizado (Stepwise)

Mediante selección automática de variables, se obtuvo un modelo más parsimonioso con las siguientes variables significativas:

Variable	Coeficiente	Error Estándar	p-valor
Intercepto	-26.31	5.99	¡0.001***
IMC Sobrepeso	2.38	0.59	¡0.001***
IMC Obesidad	16.50	1263.27	0.990
Presión Diastólica	0.29	0.07	¡0.001***
Nivel de Estrés	0.04	0.014	0.005**
Pasos Diarios	-0.40	0.18	0.025*

Cuadro 2: Coeficientes del modelo de regresión logística optimizado

Interpretación:

- El sobrepeso aumenta significativamente las probabilidades de tener problemas de sueño (OR = 10.82)
- Mayor presión diastólica se asocia con mayor riesgo de trastornos del sueño
- El estrés incrementa las probabilidades de problemas de sueño
- Mayor actividad física (pasos diarios) tiene un efecto protector

5.2. Análisis Discriminante Lineal (LDA)

5.2.1. Probabilidades A Priori

El modelo LDA estimó las siguientes probabilidades previas:

- Sin problemas de sueño: 58.7 %
- Con problemas de sueño: 41.3 %

5.2.2. Medias por Grupo

Variable	Sin Problemas	Con Problemas
Edad	39.1 años	46.2 años
Género Masculino (%)	60.8 %	33.9 %
IMC Obesidad (%)	0.0 %	7.3 %
IMC Sobrepeso (%)	8.5 %	83.1 %
Presión Sistólica	124.1 mmHg	135.0 mmHg
Presión Diastólica	81.0 mmHg	89.8 mmHg
Nivel de Estrés	50.9	57.4
Actividad Física	57.4 min	59.6 min
Frecuencia Cardíaca	69.0 bpm	71.9 bpm
Pasos Diarios	6,782	6,629

Cuadro 3: Medias por grupo en el modelo LDA

5.2.3. Coeficientes del Discriminante Lineal

Variable	Coeficiente LD1
Edad	0.011
Género Masculino	-0.335
IMC Obesidad	3.019
IMC Sobrepeso	2.399
Presión Sistólica	-0.078
Presión Diastólica	0.181
Nivel de Estrés	0.021
Actividad Física	0.002
Frecuencia Cardíaca	-0.012
Pasos Diarios	-0.196

Cuadro 4: Coeficientes del discriminante lineal

5.2.4. Métricas de Rendimiento

- **Accuracy:** 89.19 %
- **Sensitivity:** 87.10 %
- **Specificity:** 90.70 %
- **Kappa:** 0.778
- **Valor Predictivo Positivo:** 87.10 %
- **Valor Predictivo Negativo:** 90.70 %

Interpretación:

- Las personas con problemas de sueño son significativamente mayores (46.2 vs 39.1 años)
- El sobrepeso es altamente prevalente en el grupo con problemas (83.1 % vs 8.5 %)
- Mayor presión arterial tanto sistólica (+10.9 mmHg) como diastólica (+8.8 mmHg)

- Niveles de estrés más elevados (+6.5 puntos)
- Paradójicamente, mayor actividad física pero menor número de pasos diarios
- Los hombres tienen menor probabilidad de tener problemas de sueño (coeficiente negativo)
- Los coeficientes más altos corresponden a obesidad (3.02) y sobrepeso (2.40), confirmando la importancia del IMC

5.3. Árbol de Decisión

5.3.1. Modelo Original

El árbol de decisión inicial mostró una estructura compleja que fue posteriormente podada para evitar sobreajuste.

[Insertar aquí la imagen del árbol de decisión podado]

5.3.2. Interpretación del Árbol

[Completar con la interpretación de las reglas de decisión del árbol]

5.3.3. Importancia de Variables

El análisis de importancia mostró que las variables más relevantes para la clasificación son:

1. Nivel de estrés
2. Presión diastólica
3. Categoría de IMC
4. Pasos diarios

5.4. Random Forest

El modelo de Random Forest utilizó 500 árboles y mostró una tasa de error out-of-bag del 5.61 %.

Importancia de Variables (Mean Decrease Gini):

1. Nivel de estrés (mayor importancia)

2. Presión diastólica
3. Edad
4. Categoría de IMC
5. Pasos diarios

Interpretación: El modelo confirma que el estrés es el factor más importante para predecir problemas de sueño, seguido por la presión arterial diastólica y la edad.

6. Comparación de Modelos

6.1. Métricas de Rendimiento

Modelo	Accuracy	Sensitivity	Specificity	Kappa	AIC/Error
Regresión Logística	0.919	0.871	0.954	0.832	AIC: 166.44
LDA	0.892	0.871	0.907	0.778	-
Árbol (Original)	0.919	0.871	0.954	0.832	-
Árbol (Podado)	0.932	0.977	0.871	0.859	-
Random Forest	0.944	0.923	0.959	0.884	OOB: 5.61 %

Cuadro 5: Comparación de métricas de rendimiento de los modelos

6.2. Matrices de Confusión

Regresión Logística		
	No	**Sí**
No	41	4
Sí	2	27

(a) Regresión Logística

Árbol Podado		
	No	**Sí**
No	42	4
Sí	1	27

(b) Árbol de Decisión Podado

LDA		
	No	**Sí**
No	39	4
Sí	4	27

(a) Análisis Discriminante Linear

Random Forest		
	No	**Sí**
No	210	12
Sí	9	143

(b) Random Forest (datos completos)

7. Conclusiones y Recomendaciones

7.1. Modelo Recomendado

Random Forest es el modelo superior para este caso de uso por las siguientes razones:

1. **Mayor accuracy general:** 94.4 % vs. 91.9-93.2 % de otros modelos
2. **Mejor balance sensitivity/specificity:** 92.3 % y 95.9 % respectivamente
3. **Mayor robustez:** Kappa de 0.884, indicando excelente concordancia

4. **Menor tasa de error:** OOB error de solo 5.61 %
5. **Manejo de interacciones complejas:** Captura relaciones no lineales entre variables

7.2. Factores Clave Identificados

Los análisis consistentemente identificaron los siguientes factores como más importantes:

1. **Nivel de estrés:** Factor más crítico en todos los modelos
2. **Presión arterial diastólica:** Fuerte predictor de problemas de sueño
3. **Categoría de IMC:** Especialmente el sobrepeso
4. **Actividad física:** Efecto protector (pasos diarios)
5. **Edad:** Factor de riesgo importante

7.3. Implicaciones Clínicas

- **Intervenciones prioritarias:** Manejo del estrés y control de la presión arterial
- **Prevención:** Promoción de actividad física y mantenimiento de peso saludable
- **Screening:** Adultos mayores con sobrepeso y alta presión diastólica requieren mayor atención
- **Enfoque holístico:** Los problemas de sueño están multifactorialmente determinados

7.4. Limitaciones del Estudio

- Tamaño de muestra relativamente pequeño (374 observaciones)
- Datos transversales (no permiten inferir causalidad)
- Posible sesgo de selección en la población estudiada
- Variables subjetivas como nivel de estrés pueden tener variabilidad de medición

7.5. Recomendaciones Futuras

1. Validar el modelo Random Forest en una cohorte externa
2. Incluir variables adicionales como calidad de la dieta y exposición a pantallas
3. Realizar un estudio longitudinal para establecer relaciones causales
4. Desarrollar una herramienta de screening basada en el modelo validado